

Trabajo práctico final

Especialización en estadística matemática
Facultad de ciencias exactas y naturales
Universidad de Buenos Aires

Fernando Gallegos Piderit

29 de junio de 2026

Índice

1. Introducción	1
2. Análisis exploratorio	2
3. Estrategia de modelado	5
3.1. Métricas de evaluación y validación	5
3.2. Modelos a implementar	7
4. Resultados	8
4.1. Desempeño de los modelos implementados	8
4.2. Descripción de los modelos seleccionados	9
4.2.1. Bosques aleatorios	9
4.2.2. Regresión logística con penalización LASSO	11
5. Conclusiones	13
A. Especificaciones de los modelos seleccionados	15
B. Cuadros y gráficos exploratorios	17

1. Introducción

El objetivo del trabajo práctico fue construir dos clasificadores que, a partir de cierta información acerca de las características de las células que componen un tumor, permitan identificar si este es maligno o benigno con un grado aceptable de error bajo algún criterio establecido. Para ello se contó con una muestra de observaciones de tumores de los que se registraron tres medidas resumen de diez características de una cantidad desconocida de sus células mediante imágenes microscópicas. Los clasificadores obtenidos se seleccionaron de un total de seis que fueron entrenados y evaluados sobre los datos disponibles según su desempeño en ciertas métricas que reflejan los criterios antes mencionados. Como es habitual, el entrenamiento y la evaluación de los modelos se hicieron sobre un conjunto de entrenamiento y otro de *testeo* respectivamente. Los modelos evaluados fueron los siguientes: regresión logística, regresión logística con penalización LASSO, bosques aleatorios, análisis discriminante lineal y k vecinos más cercanos. De estos, los dos que mostraron el mejor desempeño fueron los bosques aleatorios y la regresión logística con penalización LASSO con las variables originales normalizadas en ambos casos.

El informe se estructura de la siguiente manera. En la sección 2 se da una descripción más detallada de los datos con los que se entrenaron los modelos de clasificación y se resaltan algunos aspectos identificados que tuvieron impacto sobre la estrategia de modelado. En la sección 3 se describe esta estrategia, en particular, algunas decisiones generales de pre-procesamiento de los datos, el método de validación, la elección de las

métricas de evaluación y su justificación y los modelos específicos a implementar. En la sección 4 se presentan los resultados de la evaluación de todos los modelos implementados sobre los datos de testeo y se detallan más específicamente los dos que mejor desempeño tuvieron junto con el procedimiento completo de modelado. Finalmente, en la sección 5 se discuten brevemente los resultados y se resaltan los puntos que resultaron más problemáticos en el desarrollo del trabajo práctico.

2. Análisis exploratorio

Los datos completos cuentan con 569 observaciones y 31 variables, de las cuales una, `target`, es la variable de respuesta que nos indica si el tumor al que corresponde cada observación es maligno (M) o benigno (B), y las demás son variables numéricas predictoras que resumen la información obtenida de las células de dichos tumores. Como se mencionó en la introducción, estas variables corresponden a tres medidas resumen (la media, el desvío estándar y el peor caso) de diez características celulares listadas a continuación:

- `radius`: El radio de las células
- `texture`: Variación en la intensidad del núcleo
- `perimeter`: Perímetro del núcleo
- `area`: Área del núcleo
- `smoothness`: Variación local del radio de las células
- `compactness`: Qué tan compacta o extendida es la célula
- `concavity`: Profundidad de las partes cóncavas del contorno de las células
- `concave`: Número de secciones cóncavas del contorno de las células
- `symmetry`: Qué tan simétrica es la forma de las células
- `fractal_dimension`: Complejidad del borde de las células

Antes de cualquier partición de los datos, observamos que la proporción de observaciones de tumores malignos es 0.3726 aproximadamente (212 observaciones); es decir, los datos están ligeramente desbalanceados. Sin embargo, dado que el desbalance no es tan marcado, se optó por no usar estratos en la partición en datos de entrenamiento y testeo para minimizar las decisiones tomadas sobre la totalidad de los datos. Se retuvo aproximadamente el 30 % de las observaciones (171) para la evaluación de los modelos y el resto se utilizó para el análisis exploratorio, el entrenamiento y la validación.

En los datos de entrenamiento la proporción de tumores malignos es 0.3643 aproximadamente. Afortunadamente no hay datos perdidos en ninguna de las variables. En el cuadro 4 se muestran algunas medidas resumen de las variables predictoras, agrupadas según la medida resumen

(valga la redundancia) a la que correspondan. Las variables predictoras tienen unidades sumamente dispares; por ejemplo, *concave_mean* tiene valores entre 0 y 0.19 secciones cóncavas mientras que *area_mean* los tiene entre 143 y 2501 unidades de área. Esta información es relevante ya que querríamos evitar que algunas características tengan mayor impacto en el entrenamiento de los modelos que otras. Todas las variables tienen rangos positivos y las posiciones de sus medias y medianas sugieren que la mayoría son asimétricas con un sesgo hacia los valores más altos.

Las figuras 1-2 y 9-16¹ ofrecen visualizaciones de las distribuciones de las variables del conjunto de datos. Cada figura corresponde a una característica de las células; la fila superior muestra histogramas de densidad según el valor de *target* para cada medida resumen y la fila inferior muestra un diagrama de dispersión por cada combinación de dos de esas medidas con los puntos coloreados según los valores de *target*.




Figura 1: Histogramas de densidad de las variables asociadas a *area* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)

Si nos enfocamos en los histogramas, se puede observar que, efectivamente, algunas variables tienen marcados sesgos hacia los valores más altos, en particular las que corresponden a los desvíos estándar de las características de los tumores. Estas variables también tienden a presentar valores extremos; esto se puede apreciar en la figura 1, por ejemplo, en el desvío estándar del área de las células. También se observa que en casi todas las variables los tumores malignos tienden a tener valores más altos. Las excepciones son las variables relacionadas con la dimensión fractal

¹La mayoría de los gráficos exploratorios se presentan en el anexo B ya que son numerosos y ocupan bastante espacio

del contorno de las células y el desvío estándar de la simetría, la suavidad y la textura. En algunos casos, como el área promedio de las células, las distribuciones condicionales a la calidad de benigno o maligno del tumor son más simétricas que la distribución general de la variable.

Un aspecto relevante de las variables es su dependencia; es de esperar que las que corresponden a las mismas características de las células estén relacionadas entre sí. Si examinamos los diagramas de dispersión de las figuras 1-2 y 9-16 vemos que, efectivamente, tienden a estar fuertemente asociadas con un patrón bastante lineal. La correlación es más fuerte entre la media y el peor caso, con el coeficiente ρ de pearson yendo de 0.688 para la simetría hasta 0.9718 para el perímetro. Es más débil entre la media y el desvío, yendo de 0.3505 para la suavidad hasta 0.8077 para el área, y entre el desvío y el peor caso, de 0.4035 para la suavidad hasta 0.86 para el área.




Figura 2: Histogramas de densidad de las variables asociadas a *smoothness* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)

Si nos enfocamos en la condición de maligno o benigno de los tumores en los diagramas de dispersión, vemos que, a diferencia de lo que se ve en los histogramas, hay fronteras bastante nítidas entre ambos tipos en algunas de las características. Esto es muy claro en las variables asociadas al radio (figura 9), el perímetro (figura 11) y el área (figura 1). En otros casos, como en las variables de suavidad (figura 2), no parece haber una frontera muy clara. Nada de esto descarta que sí exista una frontera nítida en dimensiones más altas; las visualizaciones que se hicieron no van más allá de las dos dimensiones y, teniendo 30 variables predictoras, es probable que no estemos notando patrones importantes.

3. Estrategia de modelado

Como se mencionó en la sección anterior, los datos originales se dividieron en un conjunto de entrenamiento, con aproximadamente un 70 % de las observaciones, y uno de testeo o evaluación con el resto. El primero se utilizó para entrenar y validar los modelos, y el segundo para calcular las métricas en base a las que se eligieron los dos mejores.

En términos generales, la estrategia de modelado debió tomar en cuenta los siguientes problemas. En primer lugar, el análisis exploratorio mostró que los variables predictoras tienen unidades dispares y pueden llegar a presentar correlaciones lineales muy altas. Esto llevó a la decisión de normalizar las variables y de probar estrategias de reducción de la dimensión o regularización en algunos casos. En segundo lugar, varios de los modelos propuestos (enumerados en la subsección 3.2) cuentan con uno o más hiperparámetros cuyos valores deben ser establecidos antes de la evaluación en los datos de testeo. En algunos casos se eligieron determinados valores en función de lo observado en el proceso de modelado y del costo computacional. En los casos en los que no, dichos valores se eligieron por validación cruzada de cinco folds buscando sobre grillas de valores definidas de antemano. Esto introdujo el problema de seleccionar una métrica en base a la cual elegir los valores más adecuados de los hiperparámetros. Por motivos que se detallan en la subsección 3.1 se eligió una métrica distinta a la de evaluación de los modelos. Por último, se debió establecer un umbral de predicción que determine qué casos se clasifican como malignos y cuáles como benignos.

El trabajo se realizó íntegramente en R 4.5.2 y RStudio 2025.09.2 (Posit team, 2025; R Core Team, 2025), fundamentalmente con los conjuntos de paquetes de `{tidyverse}` y `{tidymodels}` (Kuhn & Wickham, 2020; Wickham y col., 2019). Estos ofrecen una interfaz sumamente consistente para gran parte del proceso de modelado, lo cual simplificó mucho el lidiar con seis modelos distintos y todos los pasos que implica su construcción. En cuanto a los modelos en sí, `{tidymodels}` hace uso de otros paquetes para implementarlos. En este caso se usaron los paquetes `{ranger}`, `{glmnet}`, `{kknn}` y `{discrim}` (Friedman y col., 2010; Schliep & Hechenbichler, 2025; Tay y col., 2023; Wright & Ziegler, 2017).

3.1. Métricas de evaluación y validación

La elección de los dos mejores modelos se hizo en base al puntaje F_β (con $\beta = 2$) obtenido en el conjunto de testeo. Sin embargo, también se calculó la *accuracy*, la precisión, el *recall* y el área bajo la curva *precision-recall* para poder interpretar mejor los resultados. La selección del puntaje F_2 como métrica principal se basó en la consideración de las consecuencias de los falsos positivos y los falsos negativos en la identificación de tumores malignos. Durante todo el ejercicio se consideró como clase positiva a los tumores malignos.

El cuadro 1 muestra la matriz de confusión que corresponde al problema en cuestión. Un falso negativo, en este escenario², es el peor de

²Dado no estoy familiarizado con el tema y tampoco es el núcleo del trabajo práctico, para

Realidad	Predicción	
	Maligno	Benigno
Maligno	Verdadero Positivo (VP)	Falso Negativo (FN)
Benigno	Falso Positivo (FP)	Verdadero Negativo (VN)

Cuadro 1: Matriz de confusión

los resultados ya que implica que un tumor maligno no fue detectado, lo cual puede tener consecuencias graves sobre la salud de quien sea que lo tiene; si no se actúa a tiempo, el tumor puede hacer metástasis y alcanzar otras partes del cuerpo, poniendo en riesgo la vida del paciente. Un falso positivo, si bien no alcanza el mismo nivel de gravedad, sigue sin ser un buen resultado; significa que se identificó como maligno un tumor benigno, lo cual puede llevar a que la persona sufra tratamientos innecesarios. Como estamos lidiando con tumores mamarios, esto puede significar cirugías, radioterapia o quimioterapia, dependiendo de la gravedad del error. Como es razonable en cualquier problema de clasificación, el objetivo fue minimizar los casos mal clasificados, salvo que, en este caso, hay un tipo de error que es prioritario evitar por sobre el otro.

Dos métricas habituales que sirven en este caso son la precisión y el *recall*. El *recall* o *true positive rate* mide la proporción de los casos verdaderamente positivos que fueron predichos como positivos por el modelo:

$$\text{Recall} = \frac{\text{VP}}{\text{VP} + \text{FN}} \quad (1)$$

Por su parte, la precisión o *positive predictive value* mide la proporción de los predichos como positivos por el modelo que realmente son positivos:

$$\text{Precision} = \frac{\text{VP}}{\text{VP} + \text{FP}} \quad (2)$$

Ambas métricas se aproximan a 0 a medida que aumentan los casos mal clasificados, y a 1 a medida que disminuyen. Sin embargo, existe cierto *trade-off* entre ambas; si predecimos todos los casos como positivos, entonces no habrá falsos negativos y el *recall* será 1, pero inevitablemente habrá falsos positivos, por lo cual la precisión se acercará a 0. Además, puede suceder que la proporción de casos realmente positivos sobre el total sea muy alto, y que, por lo tanto, un mal modelo logre una alta precisión simplemente porque hay pocos casos realmente negativos para ser clasificados como positivos. En ese caso seguramente haya más falsos negativos y el *recall* será alto.

El puntaje F_β ofrece un balance entre ambas métricas. Es su media armónica ponderada de forma tal que el *recall* pesa β veces más que la precisión:

el razonamiento detrás de la elección de la métrica me basé en https://en.wikipedia.org/wiki/Breast_cancer

$$\begin{aligned}
F_\beta &= \frac{(1 + \beta^2)\text{Precision} \times \text{Recall}}{\beta^2\text{Precision} + \text{Recall}} \\
&= \frac{(1 + \beta^2)\text{VP}}{(1 + \beta^2)\text{VP} + \beta^2\text{FN} + \text{FP}}
\end{aligned} \tag{3}$$

La elección del valor de β representó un problema difícil de resolver en el trabajo. En principio parece evidente que un valor de $\beta = 1$ es inadecuado ya que las consecuencias de los falsos negativos son más graves que las de los falsos positivos. Sin embargo, no es claro cómo ir más allá de un orden en la gravedad de los errores. Finalmente se optó por usar un valor de $\beta = 2$, que es relativamente arbitrario ³ pero mayor a 1.

Las tres medidas presentadas requieren que se establezca un umbral de predicción que permita convertir las probabilidades de pertenencia a la clase maligna que estiman los modelos en una clasificación de las observaciones en dos clases. Este umbral se seleccionó durante la etapa de validación de los modelos en los datos de entrenamiento (esto se desarrollará en más detalle en la sección 4.2).

Como se mencionó anteriormente, para elegir los hiperparámetros de algunos modelos se realizó una validación cruzada sobre cinco folds. La métrica que se buscó maximizar en este caso fue el área bajo la curva *precision-recall*, no el puntaje F_2 , ya que la primera no depende del umbral de decisión y también refleja un balance entre ambas medidas. De lo contrario, se debería haber incluido el umbral como hiperparámetro a optimizar durante la validación cruzada, lo cual hubiese complejizado la búsqueda.

3.2. Modelos a implementar

Los modelos que se implementaron fueron los siguientes:

1. Regresión logística sobre las componentes principales de las variables predictoras normalizadas. Se optimizó el número de componentes a utilizar mediante validación cruzada. Se decidió hacer una reducción de la dimensión dada la alta correlación que se encontró entre las variables predictoras durante el análisis exploratorio.
2. Regresión logística con penalización LASSO sobre las variables predictoras originales normalizadas. Se optimizó el hiperparámetro de penalización λ mediante validación cruzada. Se incluyó este modelo ya que la penalización LASSO no sólo permite seleccionar variables relevantes, sino que también enfrenta el problema de la correlación entre las predictoras limitando el tamaño de los coeficientes.
3. Regresión logística con penalización LASSO sobre las componentes principales de las variables predictoras normalizadas. Al igual que en

³Un antecedente del campo de la bioinformática que utiliza un valor de $\beta = 2$ es Sánchez-Herrero y col., 2024. Sin embargo, otros antecedentes indican que lo más común es usar $\beta = 1$, y que, de todas formas, el puntaje F_β es inadecuado en casos clínicos (Assel & Vickers, 2025)

el modelo anterior, se optimizó el hiperparámetro λ . Se incluyó este modelo como método alternativo de selección de componentes principales; el primer modelo selecciona las primeras n componentes, mientras que este selecciona m componentes que no necesariamente son las primeras.

4. Bosques aleatorios sobre las variables predictoras originales normalizadas. Este modelo cuenta con tres hiperparámetros (al menos en la implementación usada): La cantidad de árboles por bosque, la cantidad mínima de observaciones por hoja, y la cantidad de variables a utilizar por *split* en cada árbol. Durante la validación se notó que la cantidad de árboles no afectaba notoriamente el desempeño del modelo, por lo cual se eligió usar 100 árboles y se optimizaron los otros dos parámetros (sobre grillas reducidas para no aumentar demasiado el costo computacional).
5. Análisis discriminante lineal sobre las componentes principales de las variables predictoras normalizadas. Se optimizó el número de componentes a incluir en el modelo. Se utilizaron las componentes principales ya que durante el modelado se observó que usando sólo las variables normalizadas el modelo tenía un desempeño mucho peor que el del resto.
6. K vecinos más cercanos sobre las variables predictoras originales normalizadas. Se optimizó la cantidad de vecinos.

4. Resultados

4.1. Desempeño de los modelos implementados

Modelo	F_2	Accuracy	Precision	Recall	AUC (PR)
Random Forest	0.9941	0.9883	0.9710	1.0000	0.9993
Logit LASSO	0.9911	0.9825	0.9571	1.0000	0.9993
KNN	0.9853	0.9708	0.9306	1.0000	1.0000
Logit LASSO (PCA)	0.9851	0.9883	0.9851	0.9851	0.9973
LDA	0.9735	0.9649	0.9296	0.9851	0.9961
Logit	0.9552	0.9649	0.9552	0.9552	0.9891

Cuadro 2: Métricas de los modelos en los datos de testeo

En el cuadro 2 se presentan las métricas obtenidas por cada modelo sobre los datos de testeo. Los dos modelos que alcanzaron los mayores valores en F_2 fueron el de bosques aleatorios con 0.9941, y la regresión logística con penalización LASSO sobre las variables originales con 0.9911. En ambos casos la clasificación fue casi perfecta: los bosques aleatorios lograron una precisión de 0.971 con sólo dos falsos positivos y un *recall* perfecto; la regresión logró una precisión de 0.957 con tres falsos positivos y, también, *recall* perfecto. El resto de los modelos no se quedó demasiado

atrás: El que tuvo el peor desempeño fue la regresión logística sobre las componentes principales de las variables originales con un puntaje F_2 de 0.955 y seis tumores mal clasificados, tres benignos y tres malignos.

Realidad	Predicción			
	Bosques aleatorios		Logística LASSO	
	Maligno	Benigno	Maligno	Benigno
Maligno	67	0	67	0
Benigno	2	102	3	101

Cuadro 3: Matrices de confusión de los dos mejores modelos

Es interesante notar el efecto de la ponderación en el puntaje F_β sobre el resultado. La regresión logística con penalización LASSO sobre las componentes principales de las predictoras tuvo la misma *accuracy* que el modelo de bosques aleatorios (dos tumores mal clasificados). Sin embargo, como una de sus predicciones fue un falso positivo, terminó teniendo un puntaje F_2 menor al de los bosques aleatorios.

4.2. Descripción de los modelos seleccionados

4.2.1. Bosques aleatorios

Para entrenar este modelo se utilizaron las variables originales normalizadas salvo las asociadas a la dimensión fractal (`fractal_dimension_mean`, `..._se` y `..._worst`) y el desvío estándar de la textura (`texture_se`), la suavidad (`smoothness_se`) y la simetría (`symmetry_se`), que se excluyeron dado que en los histogramas de densidad no se vió que ofrecieran capacidad de separar las dos clases de tumores. Como los árboles aleatorios utilizan una única variable por *split*, no tiene ventaja incluir aquellas cuya distribución es similar en ambas clases. Por un motivo similar se decidió no buscar las componentes principales de las variables; la alta correlación entre las predictoras no debería entrar en juego si en cada *split* sólo se usa una de ellas⁴.

Para el modelo en sí se utilizó la implementación del paquete `{ranger}` a través de `{tidymodels}`. Los hiperparámetros de este modelo son los siguientes: el número de árboles a entrenar, que, tras notar que no producía cambios notorios en la métrica de validación, se estableció en 100, un número relativamente bajo para no aumentar innecesariamente el costo computacional; el número de observaciones mínimo por hoja, que se buscó optimizar; y el número de variables a considerar en cada *split* de cada árbol, que también se optimizó. En este proceso se consideraron los valores de 10, 20 y 30 observaciones mínimas por hoja, y entre 1 y 10 variables por *split*, y se buscó sobre una grilla con todas las combinaciones de estos dos grupos de valores. Como se mencionó antes, la optimización se hizo mediante validación cruzada de cinco *folds* maximizando el área bajo la

⁴En retrospectiva, por ese mismo motivo quizás no hacía falta normalizar las predictoras.

curva *precision-recall*. Los *folds* se crearon estratificando por *target* para mantener la proporción de casos malignos dentro de cada uno.




Figura 3: Métricas según hiperparámetros optimizados. Bosques aleatorios. Los gráficos están segmentados según el número mínimo de observaciones por hoja.

En la figura 3 se puede ver la métrica de validación calculada según los hiperparámetros junto con la precisión y el *recall* calculados con un umbral de 0.5. La combinación que rindió la mayor área bajo la curva fue una variable por split y diez observaciones mínimo por hoja de cada árbol con un área bajo la curva promedio de 0.985 y error estándar de 0.004 aproximadamente. Algo que se observa es que el área no varía demasiado según el hiperparámetro, pero sí lo hacen la precisión y el *recall*.

Una vez obtenidos los hiperparámetros optimizados se utilizaron las predicciones hechas sobre los cinco *folds* para buscar el umbral de decisión óptimo que maximizase el puntaje F_2 . Esto se hizo sobre el total de las predicciones sin distinguir el *fold* al que perteneciesen. Se buscó sobre una grilla de 99 valores equiespaciados entre 0.01 y 0.99, y se tomó como óptimo el promedio de los umbrales que alcanzasen el máximo F_2 (ya que podía haber más de un valor que tocara el máximo). En la figura 4(A) se muestran las distribuciones acumuladas de las probabilidades predichas de ser un tumor maligno según la condición real del tumor y el *fold* de validación. Se ve que el modelo logra una buena separación de los casos, pero pareciera que en una buena proporción de los casos malignos las probabilidades predichas son demasiado bajas; en los cinco *folds* aproximadamente el 12.5 % tiene una probabilidad predicha menor a 0.5. La figura 4(B) muestra el puntaje F_2 alcanzado según el umbral de decisión y *fold*. Se puede ver que el máximo suele alcanzarse en valores más bajos que 0.5. La línea negra punteada se ubica en 0.29 en el eje x e indica el mejor umbral encontrado, donde se alcanza un F_2 de 0.9435.

En la figura 8 del anexo A se resumen las características del modelo final de forma más sintética.




Figura 4: Distribución acumulada de la probabilidad predicha (A) y puntaje F_2 según umbral de decisión (B). Modelo de bosques aleatorios.

4.2.2. Regresión logística con penalización LASSO

Para este modelo no se realizó una selección de variables ya que la penalización LASSO tiene como consecuencia que algunos de los coeficientes estimados de la regresión pueden ser exactamente 0. Se utilizaron todas las variables predictoras disponibles en el conjunto de datos y se las normalizó para poder implementar el modelo. El término de penalización LASSO es $\lambda \sum_{j=1}^p |\beta_j|$, donde p es la cantidad de variables predictoras y β_j es el coeficiente correspondiente a la predictora j . Como los coeficientes β_j están en la unidad de sus respectivas variables, si estas no se normalizaran aquellas con unidades más grandes (como las relacionadas con area en nuestro caso) tendrían más peso en el término y serían las primeras en perder influencia⁵.

Se utilizó la implementación del paquete `{glmnet}` mediante `{tidymodels}` de R. Este paquete, en realidad, ofrece modelos lineales generalizados con penalización *elastic net*, que es una combinación lineal de la penalización LASSO y *Ridge* (Tay y col., 2023). El hiperparámetro que controla esa combinación es α (*mixture* en la implementación usada), que se fijó en 1 para utilizar exclusivamente la penalización LASSO. Esto se hizo, por un lado, para simplificar la búsqueda de hiperparámetros óptimos y, por otro lado, porque es razonable que en este escenario sea útil seleccionar variables predictoras para luego priorizar qué aspectos de las células de los tumores medir. La búsqueda se hizo de forma análoga al modelo de bosques aleatorios; se creó una grilla de 25 valores equiespaciados en escala logarítmica de base 10 entre 10^{-6} y 10^{-1} y se seleccionó el que resultase en la mayor área bajo la curva *precision-recall*. Se utilizaron los mismos *folds* que en la validación del modelo de bosques aleatorios.

⁵De todas formas, el paquete `{glmnet}` normaliza las variables automáticamente, pero me pareció pertinente dejar por explícito, tanto en este informe como en el código de R, que es un paso de preprocesamiento.




Figura 5: Métricas según parámetro de penalización λ . Regresión logística con penalización LASSO.

La figura 5 muestra el valor de las mismas tres métricas que en el modelo anterior según el valor del hiperparámetro λ . El mejor valor encontrado fue $\lambda = 0.0056$ con un área de 0.991 y error estándar de 0.0031 aproximadamente. Se ve que cuando crece el coeficiente de penalización la precisión (con umbral 0.5) sube y el *recall* cae, seguramente porque el modelo está prediciendo mayormente negativos, lo cual reduce los falsos positivos y aumenta los falsos negativos. Para que se de este resultado, de todas formas, los verdaderos positivos no deberían bajar al mismo ritmo que los falsos positivos, caso contrario la precisión no debería cambiar mucho.




Figura 6: Distribución acumulada de la probabilidad predicha (A) y puntaje F_2 según umbral de decisión (B). Regresión logística con penalización LASSO.

La búsqueda del umbral óptimo se realizó de la misma manera que en el modelo anterior. La figura 6 es análoga a la figura 4. Se ve que este modelo también logra una buena separación de los casos y, en comparación con el anterior, asigna probabilidades más altas a los tumores malignos, con alrededor del 70 % de las observaciones malignas con probabilidad cercana a 1. Sin embargo, sigue habiendo casos de este tipo con predicciones más bajas de lo deseable que se asemejan a las de los casos benignos con predicciones más altas. El umbral que maximiza el puntaje F_2 (calculado sobre el total de predicciones sobre los *folds*) es 0.2 con un valor F_2 de 0.9595.

El modelo final estimó 12 parámetros distintos de cero, incluyendo el intercepto, que se listan en la figura 7, donde se resumen las especificaciones. Sorprendentemente, la mayor parte de las variables seleccionadas fueron los peores casos (*_worst*) de ciertas variables, específicamente, del radio, la textura, el perímetro, la suavidad, la concavidad, la cantidad de secciones cóncavas y la simetría. Fueron seleccionadas tres variables de desvío estándar (*_se*): la del radio, la compacidad y la dimensión fractal. Sólo una corresponde a la media (*_mean*), la del número de secciones cóncavas. La mayoría de las variables aumentan las chances de que el tumor sea maligno; sólo el desvío de la compacidad y de la dimensión fractal reducen esas chances.

5. Conclusiones

Los resultados del ejercicio fueron positivos; todos los modelos alcanzaron métricas sumamente altas en el conjunto de testeo con muy pocos casos mal clasificados y, más importantemente en algunos casos, sin falsos negativos. Este resultado, sin embargo, probablemente diga más sobre la calidad de los datos que sobre el ejercicio de modelado. El conjunto de datos no contaba con valores faltantes, no parecía haber errores en la información, y en general había fuertes asociaciones entre las variables predictoras y la respuesta.

Uno de los dos mejores modelos es paramétrico y el otro no paramétrico. Bosques aleatorios tuvo un desempeño marginalmente mejor, pero la regresión logística con LASSO tiene la ventaja de que, por un lado, permite reducir la cantidad de variables que es necesario medir para obtener una predicción y, por otro lado, los coeficientes que estima resultan más interpretables, sobre todo en este caso que corresponden a las variables originales normalizadas. Es posible extraer la importancia de cada variable de un modelo de bosques aleatorios, pero las medidas de importancia no son tan directamente interpretables como los coeficientes de una regresión, que tienen vínculo directo con el modelo probabilístico que usamos para conceptualizar el fenómeno. Por estos motivos considero que es preferible el modelo logístico por sobre el de bosques aleatorios.

Una de las principales dificultades del trabajo fue la falta de conocimiento sustantivo sobre el área del conocimiento a la que pertenecen los datos. Resultó difícil generar ideas a partir de las distribuciones y asociaciones observadas en la etapa de exploración al no tener noción de

la significancia científica de las variables. Finalmente se utilizaron todas las variables disponibles en casi todos los modelos ya que no hubo motivos sustantivos para excluir, combinar o transformarlas más allá de lo que exigían los modelos. Esto también impactó en la selección de la métrica de evaluación. Se optó por usar el puntaje F_β , pero, sin conocimiento del área, resultó prácticamente imposible decidir una ponderación adecuada. Por otra parte, el error puede haber estado, justamente, en la elección de esa métrica.

Referencias

- Assel, M., & Vickers, A. (2025). The F score ranks diagnostic tests and prediction models inconsistently with their clinical utility. *Diagnostic and Prognostic Research*, 9(1), 30. <https://doi.org/10.1186/s41512-025-00214-7>
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization Paths for Generalized Linear Models via Coordinate Descent. *Journal of Statistical Software*, 33(1), 1-22. <https://doi.org/10.18637/jss.v033.i01>
- Kuhn, M., & Wickham, H. (2020). *Tidymodels: A Collection of Packages for Modeling and Machine Learning Using Tidyverse Principles*. Manual.
- Posit team. (2025). *RStudio: Integrated Development Environment for R*. Manual. Boston, MA.
- R Core Team. (2025). *R: A Language and Environment for Statistical Computing*. Manual. Vienna, Austria.
- Sánchez-Herrero, S., Tondar, A., Perez-Bernabeu, E., Calvet, L., & Juan, A. A. (2024). Forecasting Survival Rates in Metastatic Colorectal Cancer Patients Undergoing Bevacizumab-Based Chemotherapy: A Machine Learning Approach. *BioMedInformatics*, 4(1), 733-753. <https://doi.org/10.3390/biomedinformatics4010041>
- Schliep, K., & Hechenbichler, K. (2025). *Kknn: Weighted k-Nearest Neighbors*. Manual. <https://doi.org/10.32614/CRAN.package.kknn>
- Tay, J. K., Narasimhan, B., & Hastie, T. (2023). Elastic Net Regularization Paths for All Generalized Linear Models. *Journal of Statistical Software*, 106(1), 1-31. <https://doi.org/10.18637/jss.v106.i01>
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemond, G., Hayes, A., Henry, L., Hester, J., Kuhn, M., Pedersen, T. L., Miller, E., Bache, S. M., Müller, K., Ooms, J., Robinson, D., Seidel, D. P., Spinu, V., ... Yutani, H. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- Wright, M. N., & Ziegler, A. (2017). ranger: A Fast Implementation of Random Forests for High Dimensional Data in C++ and R. *Journal of Statistical Software*, 77(1), 1-17. <https://doi.org/10.18637/jss.v077.i01>

A. Especificaciones de los modelos seleccionados

- Implementación: R con el paquete `{glmnet}` mediante `{tidymodels}`
- Hiperparámetros
 - Coeficiente de penalización λ : 0.0056
 - Coeficiente de mixtura α : 1 (exclusivamente LASSO)
 - Umbral de decisión: 0.2
- Preprocesamiento: Normalización de todas las variables predictoras
- Variables predictoras (entrenamiento): Todas las del conjunto de datos
- Variables predictoras (seleccionadas):

Variable	β	$\exp(\beta)$
(Intercept)	-0.4515	0.6367
concave_mean	0.6221	1.8628
radius_se	1.6863	5.3997
compactness_se	-0.3409	0.7111
fractal_dimension_se	-0.2539	0.7758
radius_worst	3.0106	20.2987
texture_worst	1.2650	3.5431
perimeter_worst	0.0266	1.0270
smoothness_worst	0.4672	1.5955
concavity_worst	0.6264	1.8710
concave_worst	1.0030	2.7264
symmetry_worst	0.3259	1.3853

Figura 7: Especificaciones del modelo de regresión logística con penalización LASSO

- Implementación: R con el paquete `{ranger}` mediante `{tidymodels}`
- Semilla: 260224
- Hiperparámetros
 - Árboles por bosque: 100
 - Variables a probar: 1
 - Mín. observaciones por hoja: 10
 - Umbral de decisión: 0.29
- Preprocesamiento: Normalización de todas las variables predictoras
- Variables predictoras: Todas menos
 - `fractal_dimension_mean`
 - `fractal_dimension_se`
 - `fractal_dimension_worst`
 - `texture_se`
 - `smoothness_se`
 - `symmetry_se`

Figura 8: Especificaciones del modelo de bosques aleatorios

B. Cuadros y gráficos exploratorios

Característica	Mín.	Máx.	Mediana	Media	s.d.
Variables con sufijo <i>_mean</i>					
radius	6.98	27.42	13.40	14.12	3.45
texture	9.71	39.28	18.92	19.37	4.49
perimeter	43.79	186.90	86.74	91.89	23.66
area	143.50	2501.00	552.95	652.74	345.16
smoothness	0.05	0.16	0.10	0.10	0.01
compactness	0.02	0.31	0.09	0.10	0.05
concavity	0.00	0.41	0.06	0.09	0.08
concave	0.00	0.19	0.03	0.05	0.04
symmetry	0.12	0.27	0.18	0.18	0.03
fractal_dimension	0.05	0.10	0.06	0.06	0.01
Variables con sufijo <i>_se</i>					
radius	0.11	2.55	0.31	0.39	0.26
texture	0.36	4.88	1.08	1.19	0.54
perimeter	0.77	18.65	2.23	2.79	1.86
area	6.80	542.20	23.66	39.10	42.09
smoothness	0.00	0.02	0.01	0.01	0.00
compactness	0.00	0.14	0.02	0.03	0.02
concavity	0.00	0.40	0.03	0.03	0.03
concave	0.00	0.05	0.01	0.01	0.01
symmetry	0.01	0.06	0.02	0.02	0.01
fractal_dimension	0.00	0.03	0.00	0.00	0.00
Variables con sufijo <i>_worst</i>					
radius	7.93	36.04	14.98	16.30	4.79
texture	12.02	49.54	25.56	25.91	6.38
perimeter	50.41	251.20	97.98	107.45	33.12
area	185.20	4254.00	691.75	882.35	573.72
smoothness	0.07	0.22	0.13	0.13	0.02
compactness	0.03	1.06	0.22	0.26	0.15
concavity	0.00	1.25	0.23	0.28	0.21
concave	0.00	0.29	0.10	0.11	0.06
symmetry	0.16	0.66	0.28	0.29	0.06
fractal_dimension	0.06	0.21	0.08	0.08	0.02

Cuadro 4: Estadísticos descriptivos de las variables según sufijo (*_mean*, *_se*, *_worst*) y característica de las células




Figura 9: Histogramas de densidad de las variables asociadas a *radius* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 10: Histogramas de densidad de las variables asociadas a *texture* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 11: Histogramas de densidad de las variables asociadas a *perimeter* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 12: Histogramas de densidad de las variables asociadas a *compactness* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 13: Histogramas de densidad de las variables asociadas a *concavity* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 14: Histogramas de densidad de las variables asociadas a *concave* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 15: Histogramas de densidad de las variables asociadas a *symmetry* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)




Figura 16: Histogramas de densidad de las variables asociadas a *fractal_dimension* según *target* (fila superior) y diagramas de dispersión de las mismas variables de a pares (fila inferior)