

Especialización en estadística matemática

Trabajo final

Notas

2025-12-15

Armé las carpetas para el proyecto. Tengo que leer bien las consignas para decidir qué hacer primero. A priori, creo que lo primero debería ser ver si la variable a predecir está desbalanceada; intuyo que sí lo está porque hay que clasificar tumores benignos y malignos y esas cosas en general están desbalanceadas. En ese caso, habría que separar los datos en train y test considerando ese desbalance. El resto de las variables son numéricas, por lo que no van a estar desbalanceadas, pero puede haber outliers.

Creo que debería hacer este primer paso en un script aparte que me deje los datos divididos en dos archivos separados. Luego continúo agarrando cada archivo por separado.

Una pregunta que me hago es: ¿debería tratar de hacer todo el procedimiento, desde exploración hasta la obtención de los resultados, en un sólo script principal, delegando las tareas específicas a funciones? ¿O debería tener varios scripts para diferentes etapas del análisis?

...

En realidad no sé si hace falta chequear el desbalanceo para hacer el split; no veo motivo para no hacer una separación estratificada. Directamente hice la separación de esta manera.

Los datos y las variables

En el conjunto de datos, cada fila representa un tumor mamario para el cual se registraron ciertas características de las células que lo componen mediante imágenes microscópicas.

La variable que hay que predecir es `target`, que indica si el tumor es benigno (B) o maligno (M). Las variables predictoras son las medias (sufijo `_mean`), los desvíos (sufijo `_se`) y los peores casos (sufijo `_worst`) de las siguientes características de las células de los tumores:

- `radius`: El radio de las células
- `texture`: Un indicador relacionado con alteraciones nucleares generalizadas
- `perimeter`: El perímetro de las células
- `area`: El área del núcleo de las células
- `smoothness`: La variación local del radio de las células (irregularidades en el borde)
- `compactness`: Medida derivada del perímetro y el área que indica qué tan compactas o extendidas son las células
- `concavity`: La profundidad de las partes cóncavas del contorno de las células
- `concave`: Cuántas secciones cóncavas tiene el contorno de las células
- `symmetry`: La simetría de las células
- `fractal_dimension`: La complejidad del borde de la célula (contornos irregulares)

Para la exploración

En principio, no tengo conocimiento del área, por lo cual no se me ocurre demasiado ... Obviamente empezaría por examinar las distribuciones de cada una de las variables para ver si habría que transformar algunas. Me imagino que debe haber varias con distribuciones medio exponenciales o log-normales.

2025-12-16

En cuanto a los estadísticos descriptivos, antes que nada debería ver si hay valores faltantes

(creo que no hay). Después, debería hacer una tabla con los siguientes estadísticos para todas las variables:

- mínimo y máximo
- percentiles 25, 50 y 75
- media
- desvío estándar
- cantidad de valores únicos (?)

... para las variables numéricas, que creo que son todas las predictoras. Para la respuesta creo que basta con sacar el porcentaje de respuestas "positivas".

Después, como indica la consigna, voy a hacer una serie de gráficos que muestren las distribuciones de las variables. Con los estadísticos descriptivos debería tener una idea de qué tan raras son las distribuciones. Con esto puedo decidir si hacer histogramas o funciones de densidad.

En ambos casos voy a tener que transformar los datos a formato *long* con las siguientes variables: *id*, *variable*, *medida*, *valor*. *variable* y *medida* me van a servir para agrupar las variables y aplicar los estadísticos descriptivos sobre *valor*. En el caso de los gráficos, me van a dejar hacer grillas de gráficos.

...

Las medidas descriptivas no me dicen demasiado. En general las distribuciones parecen estar ligeramente sesgadas hacia los valores más bajos (la media tiende a ser mayor a la mediana). En cuanto a los histogramas, todos son bastante similares: son bastante acampanadas pero con una cola más larga hacia los valores más altos. En general la distribución de los desvíos es la más asimétrica. No noté ninguna demasiado rara.

Pienso que lo que podría hacer antes de empezar a pensar los modelos y preprocesar los datos es ver si hay alguna relación entre las diferentes medidas resumen de cada característica de las células de los tumores. Podría hacer una visualización por cada característica que muestre las tres distribuciones de las medidas resumen y tres diagramas de dispersión con las tres combinaciones de variables. Lo que espero ver

es que estén asociadas, obviamente. Esto puede ser relevante, ya que puede justificar el uso de métodos de regularización.

Sobre las métricas de evaluación

Voy a tomar como "positivas" a las observaciones que tienen $\text{target} = M$, es decir, a los tumores malignos, ya que es lo que nos interesa predecir. Avanzando ya al punto 2, como estamos lidiando con posibles tumores malignos, que entiendo que pueden ser sumamente negativos para la salud, lo que queremos es tratar la mayor cantidad posible. Por lo tanto, hay que elegir métricas de evaluación de los modelos que sean buenas cuando minimicen los falsos negativos (tumores identificados como benignos cuando en realidad eran malignos).

2026-01-22

Estoy revisando los diagramas de dispersión de la media vs. el desvío, la media vs. el peor caso y el desvío vs. el peor caso de cada una de las diez características de los núcleos celulares. Como era de esperar, en muchos casos estas características están altamente correlacionadas entre sí y, además, están muy asociadas con la variable de respuesta. Salvo algunas excepciones, a mayor valor de la media, desvío o peor caso de cada característica, mayor proporción de casos malignos. La frontera es bastante marcada en la mayoría de las características también.

Estos gráficos parecerían indicar que algún tipo de reducción de la dimensión o de regularización va a ser necesaria. En el caso de la regresión logística, que seguramente sea uno de los modelos que use, podría usar regularización lasso como en otras ocasiones. En el caso del LDA y el QDA quizás pueda hacer una reducción de la dimensión con PCA. KNN y Random Forest (u otros similares que pueda llegar a usar) no deberían necesitar demasiada reducción.

En el caso de la regresión logística con lasso, la selección del parámetro de penalización va a tener que tener en cuenta la métrica de evalua-

ción. Tengo que tenerla definida de antemano entonces.

Sobre los gráficos bivariados ...

Me surge una inquietud. Estoy viendo distribuciones bivariadas de las tres medidas de cada característica, pero quizás éstas no son las más importantes. Sin embargo, hay 30 variables en total, y por lo tanto, 435 posibles distribuciones bivariadas. Me pregunto si tiene demasiado propósito explorarlas en detalle siendo que nada me asegura que las que estoy revisando sean las más relevantes. Quizás las de las medidas de cada característica sí porque tenía la intuición de que estarían muy correlacionadas, pero el resto no sé ...

2026-01-26

Para la métrica de evaluación

Tenemos la matriz de confusión:

	Predicción	
	Positivo	Negativo
Positivo	V.P.	F.N.
Negativo	F.P.	V.N.

Dado que estamos lidiando con una enfermedad grave, queremos identificar la mayor cantidad de casos realmente positivos posible; la situación más "costosa" en este problema es pasar por alto un tumor maligno, mientras que clasificar un tumor benigno como maligno es menos "costoso", al menos en términos relativos.

Una métrica que sirve es el *true positive rate* (T.P.R), *sensitivity* o *recall*:

$$\text{T.P.R.} = \frac{\text{V.P.}}{\text{V.P.} + \text{F.N.}}$$

Se ve que se aproxima a 1 si la razón entre los falsos negativos y los verdaderos positivos se aproxima a 0. Si quisiera tener en cuenta el costo de los falsos positivos se puede calcular el

puntaje F_β , que es la media armónica ponderada entre el T.P.R. y el *positive predictive value* (P.P.V.) o *precision*:

$$\text{P.P.V.} = \frac{\text{V.P.}}{\text{V.P.} + \text{F.P.}}$$

Se ve que esta medida se acerca a 1 a medida que la razón entre los falsos positivos y los verdaderos positivos se acerca a 0. El puntaje F_β , que pondera al T.P.R. β veces el P.P.V., se calcula como:

$$F_\beta = \frac{(1 + \beta^2)\text{P.P.V.} \times \text{T.P.R.}}{\beta^2\text{P.P.V.} + \text{T.P.R.}}$$

$$= \frac{(1 + \beta^2)\text{V.P.}}{(1 + \beta^2)\text{V.P.} + \beta^2\text{F.N.} + \text{F.P.}}$$

De nuevo, se ve que la medida tiende a 1 mientras menos pesan los falsos positivos y negativos respecto de los verdaderos positivos. El problema de usar esta medida es que tendría que determinar el β y no tengo ninguna formación en el tema como para saber qué tanto peor es dejar pasar un falso negativo vs. diagnosticar erróneamente a alguien que no tiene nada (más allá del sentido común).

Por ahora me parece mejor ir por el T.P.R.

Sobre las unidades de las variables

Las variables están en sus unidades originales. Tengo que decidir si estandarizarlas o no para el modelado. Las unidades son bastante variadas en su rango. Por un lado me parece razonable estandarizar para evitar el mayor peso de una variable sobre otra si es que reduzco la dimensionalidad o algo así. Por otro lado, dado que las variables están "agrupadas", en cierto sentido, me pregunto si tiene sentido estandarizar las "_mean", "_se" y "_worst".

¿Qué es lo que me preocupa exactamente? Me preocupa que, al estandarizar las variables por separado, se pierda algo de información. En particular, me preocupa que no se pueda ver si la variabilidad en la característica de la célula es grande o chica respecto del promedio de esa

característica. Calculé el coeficiente de variación (se / mean) de cada característica y grafiqué un histograma y un diagrama de dispersión vs. la medida se. No estoy seguro de las conclusiones, debería hacerlo de nuevo.

Sobre los modelos

El paquete MASS tiene las funciones `lda` y `qda` para hacer *linear discriminant analysis* y *quadratic discriminant analysis*. Los objetos que devuelven esas funciones pueden dar predicciones con la función `predict`. Podría ver si hay mejores paquetes para usar. Para *random forests* está el paquete *RandomForest* que ya he usado bastante y anda bien. Para *KNN* estaba el paquete *FNN*.

Quizás debería tener una única función que calcule la métrica que me interesa, cosa que tome un vector de predicciones y otro de valores reales y que devuelva la métrica. De esta forma puedo usar lo mismo para todos los modelos.

O quizás debería considerar usar la familia de paquetes de `tidymodels`; puede ser una buena oportunidad para aprender a usarlos, a pesar de que en general me gusta usar la menor cantidad de paquetes posibles.

2026-02-07

Empecé a avanzar con el ajuste de los modelos. Por ahora los modelos que voy a probar son:

1. Regresión logística sobre componentes principales
2. Regresión logística con regularización LASSO
3. Análisis discriminante lineal
4. ?
5. ?

Estoy probando hacer el ajuste de los modelos usando la familia de paquetes de `tidymodels`. Creo que queda todo bastante ordenado de esta manera. De todas maneras mi aproximación fue bastante superficial y me gustaría tener un poco más de certeza de que estoy haciendo las

cosas bien. Voy a seguir probando y examinando los resultados de cada paso para convencerme de que está todo en orden. En particular quiero chequear que la validación cruzada del parámetro λ con LASSO está andando bien. Para ello quisiera poder replicar los gráficos que da normalmente la función `cv.glmnet`. También me quedaría por ver cómo obtener las métricas de los modelos una vez ajustados.

2026-02-10

Seguí avanzando con `tidymodels`. Me trabé con una pelotudez y me tilteé. Además encontré un problema. No debería ser demasiado serio si lo logro evadirlo en el TP. El problema es que con todo el *aparatus* de `tidymodels` puedo ajustar los modelos y calibrar los hiperparámetros con validación cruzada, pero no puedo calibrar el umbral de predicción. Tendría que hacerlo una vez ajustado el modelo. Este problema también impacta en la calibración del hiperparámetro λ ya que estoy seleccionándolo en base al puntaje F_1 , que se calcula a partir de la matriz de confusión que, a su vez, depende del umbral de predicción.

Fuera de eso creo que logré avanzar algo. Me quedarían por elegir un par de modelos y ver cómo hacer PCA en el marco de `tidymodels`.

2026-02-17

Finalmente estoy usando el área bajo la curva *precision-recall* como medida para optimizar los hiperparámetros. La elegí porque ambas medidas son relevantes para el problema actual y porque esa área no depende del umbral de decisión, sino que los toma a todos en cuenta. La optimización la hago mediante validación cruzada con 5 *folds*. Una vez optimizado el modelo, tomo las predicciones hechas sobre todos los *folds* y busco el umbral que me da el mejor F_β . En caso de que nos sea dramáticamente distinto de 0.5 simplemente elijo ese valor por simplicidad. El problema sigue siendo cuál es el mejor valor de β . Esto depende de cuánto peor crea que sea que se nos pase un caso con cáncer

vs. diagnosticar con cáncer a alguien que no lo tiene. Tiendo a pensar que lo primero pesa más que lo segundo, pero me es imposible decidir *cuánto más*.

Por otro lado, ya vi como hacer PCA en el marco de `tidymodels`. Tomé el número de componentes como hiperparámetro y optimizé el modelo con VC de cinco *folds* de la misma manera que el modelo anterior. El resto del procedimiento es casi idéntico.

En el caso de los bosques aleatorios, no sé si calibrar o no los hiperparámetros que tiene el modelo. Como son tres la grilla podría llegar a ser muy grande. Además, haciendo pruebas me dio la impresión de que no había grandes cambios; lo que más afectaba era la cantidad de variables a probar por `split`, `mtry`.

En cuanto a la búsqueda del umbral de decisión, empiezo a dudar si es correcto elegirlo sobre las predicciones hechas para los cinco folds en simultáneo. Pasa que sí o sí hay que tener una manera de agregar los umbrales óptimos para cada fold, y esa parece la manera menos problemática. Sino tendría que hacer algún tipo de promedio entre folds, pero ahí está el problema de que en algunos no hay *un* mejor umbral, sino que hay un intervalo de mejores umbrales.

Por último, pienso si no será mejor hacer PCA en los datos en general y luego aplicar los modelos. Por una parte, esto haría que los datos sean “los mismos” para cada modelo. Por otro lado, agregaría la complicación de elegir el número de componentes. Podría ser como hiperparámetro, pero ahí me infla ese problema en los otros modelos. Además sería medio redundante hacer eso en el caso de LASSO, que ya de entrada hace selección de variables.

Algo que me tengo que fijar es cómo obtener los parámetros de algunos modelos (los que tienen). También tendría que sacar las cargas del PCA.